

AN INVESTIGATION INTO THE APPLICATION OF CONVOLUTIONAL NEURAL NETWORKS IN IMAGE CLASSIFICATION TASKS

Ngo Anh Duong, Nguyen Quang Vinh, Nguyen Huu Minh Hoang, Ha Thi Thanh Tam

University of Transport Technology, No. 54 Trieu Khuc Street, Thanh Liet Ward, Hanoi, Vietnam

Article info

Type of article:

Original research paper

Corresponding author:

Ha Thi Thanh Tam

E-mail address:

tamhtt@utt.edu.vn

Received:

Accepted:

Published:

Abstract: Covering over 70% of the Earth's surface, water is a critical element that plays a central role in almost every aspect of life. However, alongside advancements in science and technology, aquatic environments are facing major pollution challenges, among which water turbidity serves as a key parameter for assessing water quality. This paper investigates and evaluates the effectiveness of the VGG-16 convolutional neural network architecture in classifying water turbidity. For this task, the model was trained on a dataset of 240 images and evaluated on a test set of 25 images, achieving a classification accuracy of 92.00%. Furthermore, the proposed approach was applied to waste classification, where the model was trained on a dataset of 1300 images categorized into four classes (organic, inorganic, hazardous, and recyclable waste), attaining an accuracy of 90.13%. Experimental results demonstrate that VGG-16 possesses robust feature extraction capabilities and achieves high classification performance across datasets with distinct characteristics.

Keywords: Convolutional Neural Networks, VGG-16, Deep Learning, Computer Vision, Image Classification, Image Processing.

TÌM HIỂU VỀ ỨNG DỤNG MẠNG NƠ RON TÍCH CHẬP TRONG MỘT SỐ BÀI TOÁN PHÂN LOẠI ẢNH

Ngô Ánh Dương, Nguyễn Quang Vinh, Nguyễn Hữu Minh Hoàng, Hà Thị Thanh Tâm

Trường Đại học Công nghệ Giao thông vận tải, Số 54 phố Triều Khúc, phường Thanh Liệt, Hà Nội, Việt Nam

Thông tin bài viết

Tác giả liên hệ:

Hà Thị Thanh Tâm

Địa chỉ E-mail:

tamhtt@utt.edu.vn

Ngày nộp bài:

Ngày chấp nhận:

Ngày đăng bài:

Tóm tắt: Chiếm hơn 70% diện tích bề mặt trái đất, nước là yếu tố cốt lõi, chi phối hầu hết các mặt của đời sống. Tuy nhiên, cùng với sự phát triển của khoa học, kỹ thuật, môi trường nước đang đứng trước những thách thức lớn về ô nhiễm, trong đó độ đục của nước đóng vai trò vô cùng quan trọng trong việc đánh giá chất lượng nước. Bài báo này khảo sát và đánh giá hiệu quả của kiến trúc mạng nơ ron tích chập VGG-16 trong bài toán phân loại độ đục của nước. Đối với bài toán này, chúng tôi sử dụng tập huấn luyện gồm 240 ảnh, với 25 ảnh test. Kết quả cho thấy, độ chính xác trong nhận dạng là 92.00%. Bên cạnh đó, chúng tôi cũng áp dụng mô hình cho bài toán phân loại rác thải, mô hình được huấn luyện trên tập dữ liệu gồm 1300 ảnh thuộc bốn lớp (rác hữu cơ, rác vô cơ, rác nguy hại và rác tái chế), đạt độ chính xác 90.13%. Kết quả thực nghiệm cho thấy VGG-16 có khả năng trích xuất đặc trưng hiệu quả và đạt hiệu năng phân loại cao trên các tập dữ liệu có đặc điểm khác nhau.

Từ khóa: Mạng nơ ron tích chập, VGG-16, học sâu, thị giác máy tính, phân loại ảnh, xử lý ảnh.

1. Tổng quan

Mạng nơ ron nhân tạo (Artificial Neural Network – ANN), thường được gọi ngắn gọn là Neural Network (NN), là một mô hình học máy được xây dựng dựa trên nguyên lý hoạt động của hệ thần kinh sinh học. Ý tưởng về mạng nơ ron nhân tạo được đề xuất lần đầu tiên bởi Warren McCulloch và Walter Pitts trong bài báo "A Logical Calculus of the Ideas Immanent in Nervous Activity" công bố năm 1943. Nghiên cứu này đã đặt nền móng cho sự phát triển của lĩnh vực mạng nơ ron và trí tuệ nhân tạo hiện đại [1].

Mạng nơ ron nhân tạo bao gồm nhiều đơn vị xử lý gọi là nơ ron (neurons), được liên kết với nhau thông qua các trọng số (weights) để mô

phỏng quá trình xử lý thông tin của não bộ. Dữ liệu được truyền từ lớp đầu vào qua một hoặc nhiều lớp ẩn, sau đó tạo ra kết quả tại lớp đầu ra. Trong quá trình huấn luyện, các trọng số được điều chỉnh nhằm giảm sai số giữa giá trị dự đoán và giá trị thực tế, từ đó giúp mô hình học được các đặc trưng của dữ liệu [2].

Một mạng nơ ron nhân tạo cơ bản gồm ba thành phần chính:

- Lớp đầu vào (Input Layer): Tiếp nhận dữ liệu đầu vào của mô hình.
- Lớp ẩn (Hidden Layer): Thực hiện các phép biến đổi và trích xuất đặc trưng từ dữ liệu.

- Lớp đầu ra (Output Layer): Đưa ra kết quả dự đoán cuối cùng.

Đối với một nơ ron, tổng tín hiệu đầu vào được xác định theo công thức [2]:

$$h = g(W^T x + b) \quad (1)$$

Trong đó:

- x : vector dữ liệu đầu vào
- W^T : vector trọng số
- b : hệ số bù (bias)
- g : hàm kích hoạt
- h : giá trị đầu ra của nơ ron

Quá trình huấn luyện mạng nơ ron bao gồm hai giai đoạn chính là lan truyền tiến (Forward Propagation) và lan truyền ngược (Backward Propagation). Trong quá trình này, các trọng số được cập nhật liên tục nhằm giảm thiểu sai số giữa kết quả dự đoán và giá trị thực tế [1], [2].

Mạng nơ ron truyền thẳng (Feedforward Neural Network – FNN) là dạng đơn giản nhất của mạng nơ ron nhân tạo. Nền tảng của mô hình này được đặt ra bởi Frank Rosenblatt thông qua mô hình Perceptron được công bố vào năm 1958 [3]. Trong kiến trúc này, dữ liệu được truyền theo một chiều từ lớp đầu vào, qua các lớp ẩn và đến lớp đầu ra mà không tồn tại cơ chế phản hồi ngược [1], [3]. FNN được ứng dụng rộng rãi trong các bài toán phân loại và dự đoán dữ liệu nhờ cấu trúc đơn giản và khả năng mô hình hóa các mối quan hệ phi tuyến.

Cấu trúc của FNN bao gồm các lớp kết nối đầy đủ (Fully Connected Layer), trong đó mỗi nơ ron ở một lớp sẽ được kết nối với tất cả nơ ron của lớp kế tiếp.

Quá trình lan truyền trong FNN được biểu diễn như sau:

$$a^{(l)} = g(W^{(l)} a^{(l-1)} + b^{(l)}) \quad (2)$$

Trong đó:

- $a^{(l)}$: đầu ra của lớp thứ l
- $W^{(l)}$: là ma trận trọng số
- $b^{(l)}$: vecto độ lệch
- g : hàm kích hoạt

FNN được ứng dụng rộng rãi trong các bài toán phân loại và dự đoán dữ liệu dạng bảng. Tuy nhiên, đối với bài toán xử lý ảnh, mô hình này bộc lộ nhiều hạn chế do phải chuyển đổi ảnh thành vector một chiều, làm mất đi thông tin không gian giữa các điểm ảnh và gia tăng đáng kể số lượng tham số cần huấn luyện [2], [3].

Mạng nơ ron sâu (Deep Neural Network – DNN) là sự phát triển của mạng nơ ron truyền thẳng bằng cách bổ sung nhiều lớp ẩn nhằm tăng khả năng học các đặc trưng phức tạp của dữ liệu [2], [4]. Khái niệm này được phát triển và hoàn thiện bởi nhiều nhà nghiên cứu, nổi bật là Geoffrey Hinton, Yann LeCun và Yoshua Bengio [4], [5]. Nhờ khả năng biểu diễn dữ liệu ở nhiều mức độ trừu tượng khác nhau, DNN đã trở thành nền tảng quan trọng cho sự phát triển của lĩnh vực học sâu (Deep Learning).

Không giống như các mô hình truyền thống, DNN có khả năng học các biểu diễn dữ liệu ở nhiều mức độ trừu tượng khác nhau. Các lớp đầu tiên thường học những đặc trưng cơ bản, trong khi các lớp phía sau sẽ kết hợp chúng để tạo thành các đặc trưng phức tạp hơn [4], [5].

Cấu trúc tổng quát của DNN được mô tả như sau:

$$x \rightarrow h_1 \rightarrow h_2 \rightarrow \dots \rightarrow h_n \rightarrow y \quad (3)$$

Trong đó:

- x : dữ liệu đầu vào
- h_i : các lớp ẩn
- y : kết quả đầu ra

Mặc dù DNN đạt hiệu quả cao trong nhiều lĩnh vực, việc huấn luyện các mô hình có số lượng lớp lớn thường đòi hỏi khối lượng dữ liệu lớn, thời gian xử lý dài và tài nguyên tính toán mạnh [2], [4].

FNN, DNN và CNN đều là các biến thể của mạng nơ ron nhân tạo nhưng có sự khác biệt về cấu trúc và phương pháp xử lý dữ liệu.

FNN sử dụng các lớp kết nối đầy đủ và phù hợp với dữ liệu dạng bảng. DNN phát triển FNN bằng cách bổ sung thêm nhiều lớp ẩn nhằm tăng khả năng học đặc trưng. Trong khi đó, CNN được

thiết kế chuyên biệt cho dữ liệu hình ảnh thông qua các lớp tích chập và lớp gộp mẫu, giúp mô hình bảo toàn được thông tin không gian và giảm số lượng tham số cần huấn luyện [2], [4], [6].

Nhờ những ưu điểm này, CNN hiện được ứng dụng rộng rãi trong các bài toán thị giác máy tính, nhận dạng đối tượng và phân loại ảnh.

1.1. Cơ sở lý thuyết về CNN

Mạng nơ ron tích chập (Convolutional Neural Network - CNN) là một loại mạng nơ ron học sâu được thiết kế đặc biệt để xử lý các dữ liệu có cấu trúc dạng lưới. Ý tưởng về mạng nơ ron tích chập được phát triển bởi Yann LeCun cùng các cộng sự vào cuối những năm 1980 và được giới thiệu rộng rãi trong bài báo "Gradient-Based Learning Applied to Document Recognition" công bố trên *Proceedings of the IEEE* năm 1998 [6]. Dạng dữ liệu phổ biến nhất mà CNN xử lý là hình ảnh, được biểu diễn dưới dạng ma trận hai chiều của các điểm ảnh trên từng kênh màu. Không giống như mạng nơ ron truyền thẳng (Feedforward Neural Network - FNN), CNN được thiết kế nhằm khai thác cấu trúc không gian của dữ liệu ảnh thông qua các phép tích chập (convolution), cho phép mô hình tự động học và trích xuất các đặc trưng quan trọng từ dữ liệu đầu vào mà không cần xây dựng đặc trưng thủ công [6].

Kiến trúc CNN lần đầu được phát triển thành công với mô hình LeNet-5 do LeCun và cộng sự đề xuất vào năm 1998 trong bài toán nhận dạng chữ viết tay. Mô hình này đã đặt nền tảng cho sự phát triển của các kiến trúc CNN hiện đại [6]. Đến năm 2012, sự ra đời của AlexNet đã tạo nên bước đột phá trong cuộc thi ImageNet Large Scale Visual Recognition Challenge (ILSVRC), khi đạt độ chính xác vượt trội so với các phương pháp truyền thống, qua đó khẳng định hiệu quả của học sâu trong bài toán phân loại ảnh [6]. Trên cơ sở đó, nhiều kiến trúc CNN có độ sâu lớn hơn như VGGNet, GoogLeNet, ResNet và DenseNet đã lần lượt được phát triển nhằm nâng cao khả năng học biểu diễn và cải thiện hiệu năng phân loại dữ liệu [7], [8], [9].

Một mạng CNN bao gồm nhiều lớp được liên kết tuần tự với nhau để thực hiện quá trình trích

xuất đặc trưng và phân loại dữ liệu. Các thành phần chính của CNN gồm:

- Lớp tích chập (Convolutional Layer): thực hiện phép tích chập giữa ảnh đầu vào và các bộ lọc (Kernel/Filter) để tạo ra các bản đồ đặc trưng (Feature Maps).
- Lớp kích hoạt (Activation Layer): áp dụng hàm kích hoạt nhằm tăng khả năng biểu diễn phi tuyến của mô hình, trong đó phổ biến nhất là hàm ReLU (Rectified Linear Unit).
- Lớp gộp (Pooling Layer): giảm kích thước của bản đồ đặc trưng, giữ lại các đặc trưng quan trọng và giảm chi phí tính toán.
- Lớp kết nối đầy đủ (Fully Connected Layer): tổng hợp các đặc trưng đã học và thực hiện quá trình phân loại thông qua hàm Softmax.

Tại lớp tích chập, đầu ra của một đặc trưng được tính theo công thức:

$$y(i, j) = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} x(i+m, j+n)w(m, n) + b \quad (4)$$

Trong đó:

- $x(i+m, j+n)$: giá trị điểm ảnh đầu vào
- $w(m, n)$: trọng số của bộ lọc
- b : hệ số dịch (bias)
- $y(i, j)$: giá trị của bản đồ đặc trưng sau phép tích chập

Sau lớp tích chập, hàm kích hoạt ReLU được sử dụng để loại bỏ các giá trị âm và tăng khả năng học của mô hình:

$$f(x) = \max(0, x) \quad (5)$$

Tiếp theo, lớp Max Pooling thực hiện giảm kích thước đặc trưng bằng cách giữ lại giá trị lớn nhất trong mỗi vùng quan sát:

$$y = \max(x_1, x_2, \dots, x_n) \quad (6)$$

Cuối cùng, sau khi dữ liệu được làm phẳng (Flatten), lớp kết nối đầy đủ sử dụng hàm Softmax để tính xác suất mẫu dữ liệu thuộc từng lớp:

$$P(y=i) = \frac{e^{z_i}}{\sum_{j=1}^C 1e^{z_j}} \quad (7)$$

Trong đó:

- z_i : giá trị đầu ra của lớp thứ i
- C : số lớp cần phân loại
- $P(y=i)$: xác suất mẫu dữ liệu thuộc lớp i

Nhờ khả năng tự động học và trích xuất đặc trưng theo nhiều mức độ từ dữ liệu đầu vào, CNN đã chứng minh hiệu quả vượt trội so với các phương pháp xử lý ảnh truyền thống trong nhiều bài toán phân loại ảnh. Đồng thời, sự phát triển của các kiến trúc CNN hiện đại đã góp phần nâng cao đáng kể độ chính xác, khả năng tổng quát hóa và hiệu quả tính toán, mở rộng phạm vi ứng dụng của học sâu trong nhiều lĩnh vực như y tế, nông nghiệp, giao thông, công nghiệp và bảo vệ môi trường [7], [8], [9].

1.2. Tổng quan về bài toán phân loại ảnh

1.2.1. Khái niệm và phân loại bài toán

Phân loại ảnh (Image Classification) là một trong những bài toán nền tảng của lĩnh vực thị giác máy tính, với mục tiêu xác định và gán nhãn cho một hình ảnh dựa trên nội dung mà hình ảnh đó chứa. Trong bài toán này, mô hình sẽ phân tích các đặc trưng của ảnh đầu vào và dự đoán ảnh thuộc lớp nào trong tập các lớp đã được xác định trước.

Các phương pháp phân loại ảnh truyền thống thường yêu cầu quá trình thiết kế đặc trưng (feature engineering) thủ công trước khi đưa dữ liệu vào bộ phân loại. Tuy nhiên, cách tiếp cận này phụ thuộc nhiều vào kinh nghiệm của người nghiên cứu và thường gặp khó khăn khi xử lý các tập dữ liệu có kích thước lớn hoặc chứa nhiều đặc trưng phức tạp. Sự ra đời của mạng nơ ron tích chập đã thay đổi đáng kể cách tiếp cận bài toán phân loại ảnh khi cho phép mô hình tự động học và trích xuất đặc trưng trực tiếp từ dữ liệu đầu vào, từ đó cải thiện đáng kể hiệu quả phân loại và khả năng tổng quát hóa của mô hình [4], [10].

Bài toán phân loại ảnh là quá trình xây dựng mô hình có khả năng ánh xạ một hình ảnh đầu

vào vào một hoặc nhiều lớp nhãn đã được xác định trước. Trong quá trình huấn luyện, mô hình học các đặc trưng của từng lớp dữ liệu thông qua tập dữ liệu đã gán nhãn. Khi nhận một ảnh mới, mô hình sẽ phân tích các đặc trưng đã học và đưa ra dự đoán lớp có xác suất cao nhất [4].

Dựa trên số lượng nhãn và đặc điểm của tập dữ liệu, bài toán phân loại ảnh thường được chia thành ba dạng chính, bao gồm phân loại nhị phân (Binary Classification), phân loại đa lớp (Multi-class Classification) và phân loại đa nhãn (Multi-label Classification). Trong đó, phân loại nhị phân là bài toán mà mỗi ảnh chỉ được gán vào một trong hai lớp dữ liệu, chẳng hạn như xác định ảnh có hoặc không chứa đối tượng cần nhận diện. Đối với phân loại đa lớp, mỗi ảnh chỉ thuộc duy nhất một lớp trong nhiều lớp đã được xác định trước. Đây là dạng bài toán phổ biến nhất trong lĩnh vực phân loại ảnh và được ứng dụng rộng rãi trong nhiều nghiên cứu, điển hình như phân loại rác thành các nhóm rác hữu cơ, rác vô cơ, rác nguy hại và rác tái chế hoặc phân loại các mức độ đục của nước. Trong khi đó, phân loại đa nhãn là bài toán mà một ảnh có thể đồng thời thuộc nhiều lớp khác nhau. Loại bài toán này thường xuất hiện trong các hệ thống nhận dạng cảnh hoặc nhận dạng nhiều đối tượng cùng lúc trong một hình ảnh, khi mỗi ảnh có thể chứa nhiều đối tượng hoặc nhiều thuộc tính cần được gán nhãn [7], [11].

Trong nghiên cứu này, hai bài toán thực nghiệm là phân loại rác và phân loại độ đục của nước đều thuộc dạng phân loại đa lớp (Multi-class Classification), trong đó mỗi ảnh chỉ được gán vào một nhãn duy nhất.

1.2.2. Các tiêu chí đánh giá bài toán phân loại ảnh

Để đánh giá hiệu quả của một mô hình phân loại và xác định mức độ chính xác cũng như khả năng tổng quát hóa dữ liệu. Các chỉ số phổ biến thường được sử dụng bao gồm:

Accuracy (Độ chính xác): Là chỉ số biểu thị tỷ lệ số lượng dự đoán đúng của mô hình trên tổng số mẫu dữ liệu được đánh giá. Giá trị Accuracy

càng cao chứng tỏ mô hình có khả năng phân loại càng tốt [12].

$$\begin{aligned} Accuracy &= \frac{\text{Số mẫu phân loại đúng}}{\text{Tổng số mẫu phân loại}} \\ &= \frac{TP + TN}{TP + TN + FP + FN} \end{aligned} \quad (8)$$

trong đó TP (True Positive) là số lượng mẫu thuộc lớp dương được dự đoán đúng, TN (True Negative) là số lượng mẫu thuộc lớp âm được dự đoán đúng, FP (False Positive) là số lượng mẫu thuộc lớp âm nhưng bị dự đoán sai thành lớp dương, FN (False Negative) là số lượng mẫu thuộc lớp dương nhưng bị dự đoán sai thành lớp âm.

Precision (Độ chính xác dương): Đo lường tỷ lệ các mẫu được dự đoán là dương tính mà thực tế cũng thuộc lớp dương tính, giúp đánh giá độ tin cậy của các dự đoán dương [12].

$$\begin{aligned} Precision &= \frac{\text{Số lượng mẫu dương dự đoán đúng}}{\text{Tổng số mẫu được dự đoán là đúng}} \\ &= \frac{TP}{TP + FP} \end{aligned} \quad (9)$$

Recall (Độ bao phủ): Phản ánh khả năng của mô hình trong việc phát hiện đầy đủ các mẫu thực sự thuộc lớp dương tính trong tập dữ liệu [12].

$$Recall = \frac{TP}{TP + FN} \quad (10)$$

F1-score là trung bình điều hòa của Precision và Recall, được sử dụng để đánh giá tổng hợp hiệu quả của mô hình, đặc biệt trong trường hợp dữ liệu giữa các lớp không cân bằng [12].

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (11)$$

Bên cạnh các chỉ số định lượng, Confusion Matrix (Ma trận nhầm lẫn) là một công cụ quan trọng để phân tích chi tiết kết quả, biểu diễn số lượng dự đoán đúng và sai của từng lớp đối

tượng, giúp người nghiên cứu nhận diện các lỗi nhầm lẫn cụ thể của mô hình [12].

2. Kiến thức cơ sở


Sự phát triển của mạng nơ ron tích chập đã tạo nên nhiều bước tiến quan trọng trong lĩnh vực thị giác máy tính. Qua từng giai đoạn phát triển, nhiều kiến trúc CNN được đề xuất nhằm nâng cao khả năng học đặc trưng, cải thiện độ chính xác và tối ưu hiệu quả tính toán trong các bài toán phân loại ảnh. Trong số đó, LeNet-5, AlexNet và VGGNet được xem là những kiến trúc tiêu biểu, đánh dấu các cột mốc quan trọng trong quá trình phát triển của học sâu và đặt nền tảng cho nhiều mô hình CNN hiện đại [6], [7], [10].

2.1. LeNet-5

LeNet-5 là một trong những kiến trúc CNN đầu tiên được đề xuất bởi Yann LeCun và cộng sự vào năm 1998 nhằm giải quyết bài toán nhận dạng chữ số viết tay trong bộ dữ liệu MNIST [6]. Đây được xem là mô hình đặt nền móng cho sự phát triển của các kiến trúc CNN hiện nay.

Kiến trúc LeNet-5 bao gồm bảy lớp có tham số, được tổ chức theo trình tự các lớp tích chập (Convolutional Layer), lớp gộp (Pooling Layer) và các lớp kết nối đầy đủ (Fully Connected Layer). Trong quá trình xử lý, các lớp tích chập có nhiệm vụ trích xuất những đặc trưng cơ bản như cạnh, đường nét và hình dạng của đối tượng, trong khi các lớp pooling giúp giảm kích thước đặc trưng và hạn chế hiện tượng quá khớp (overfitting). Cuối cùng, các lớp kết nối đầy đủ thực hiện quá trình phân loại dựa trên các đặc trưng đã học được [6].

Mặc dù LeNet-5 có số lượng tham số tương đối nhỏ và chỉ phù hợp với các tập dữ liệu có kích thước hạn chế, kiến trúc này đã chứng minh hiệu quả của việc sử dụng phép tích chập trong nhận dạng ảnh, đồng thời trở thành nền tảng cho sự ra đời của nhiều kiến trúc CNN hiện đại.



Hình 1. Kiến trúc mạng LeNet-5


2.2. AlexNet

Năm 2012, AlexNet được đề xuất bởi Alex Krizhevsky, Ilya Sutskever và Geoffrey Hinton, tạo nên bước đột phá trong cuộc thi ImageNet Large Scale Visual Recognition Challenge (ILSVRC) khi giảm đáng kể tỷ lệ lỗi so với các phương pháp truyền thống [10].

So với LeNet-5, AlexNet có kiến trúc sâu hơn với tám lớp học, bao gồm năm lớp tích chập và ba lớp kết nối đầy đủ. Một trong những điểm nổi bật của AlexNet là việc sử dụng hàm kích hoạt

Rectified Linear Unit (ReLU) thay cho các hàm kích hoạt truyền thống nhằm tăng tốc quá trình hội tụ của mô hình. Ngoài ra, mô hình còn áp dụng kỹ thuật Dropout để giảm hiện tượng quá khớp và Data Augmentation nhằm tăng khả năng tổng quát hóa của mô hình trên dữ liệu chưa từng xuất hiện [10].

Sự thành công của AlexNet đã khẳng định tiềm năng của học sâu trong các bài toán xử lý ảnh và mở ra một giai đoạn phát triển mạnh mẽ của các kiến trúc CNN có độ sâu lớn hơn.



Hình 2. Kiến trúc mạng AlexNet

2.3. VGGNet

VGGNet là kiến trúc CNN được đề xuất bởi Karen Simonyan và Andrew Zisserman thuộc Visual Geometry Group (VGG) của Đại học Oxford trong nghiên cứu “Very Deep Convolutional Networks for Large-Scale Image Recognition” năm 2014 [7]. Tên gọi VGG được lấy theo tên viết tắt của nhóm nghiên cứu.

VGGNet có hai phiên bản phổ biến là VGG-16 và VGG-19, trong đó các số 16 và 19 biểu thị tổng số lớp (layer) có trong mô hình.


Khác với AlexNet, VGGNet sử dụng các bộ lọc tích chập kích thước nhỏ $[3 \times 3]$ được xếp chồng liên tiếp thành các khối tích chập. Cách thiết kế này giúp mô hình tăng khả năng học các đặc trưng phức tạp mà vẫn giữ số lượng tham số ở mức hợp lý. Sau mỗi khối tích chập là một lớp

Max Pooling có nhiệm vụ giảm kích thước bản đồ đặc trưng, từ đó giảm chi phí tính toán và hạn chế hiện tượng quá khớp (overfitting). Bên cạnh đó, VGGNet tiếp tục sử dụng hàm kích hoạt ReLU được kế thừa từ AlexNet nhằm tăng khả năng biểu diễn phi tuyến và cải thiện tốc độ hội tụ của mô hình [7].

Một trong những điểm cải tiến quan trọng của VGGNet là đưa ra khái niệm khối tích chập (Convolutional Block), trong đó nhiều lớp tích chập được sắp xếp liên tiếp trước khi thực hiện phép gộp. Thiết kế này đã trở thành kiến trúc mẫu

cho nhiều mạng CNN được phát triển sau này như ResNet, DenseNet và EfficientNet [7], [9].

Trong nghiên cứu này, VGG-16 được lựa chọn làm mô hình thực nghiệm chính nhờ cấu trúc đơn giản, khả năng trích xuất đặc trưng hiệu quả và đã được chứng minh đạt hiệu năng cao trên nhiều bài toán phân loại ảnh. Ngoài ra, mô hình còn hỗ trợ tốt phương pháp Transfer Learning, giúp rút ngắn thời gian huấn luyện và nâng cao độ chính xác khi làm việc với các tập dữ liệu có quy mô vừa và nhỏ.



Hình 3. Kiến trúc mạng VGG-16

3. Thực nghiệm và đánh giá

3.1. Quy trình thực nghiệm


Quy trình thực nghiệm trong nghiên cứu được xây dựng chung cho cả hai bài toán phân loại rác và phân loại độ đục của nước, bao gồm các bước (Hình 4):

- Thu thập dữ liệu: Dữ liệu hình ảnh được thu thập bằng camera điện thoại thông minh, đảm bảo chất lượng ảnh và tính đa dạng về góc chụp. Sau khi thu thập, dữ liệu được tiền xử lý ảnh được đưa về dạng chuẩn 224x224 pixel, gán nhãn theo từng lớp.
- Phân chia dữ liệu: Dữ liệu được phân chia thành ba tập dữ liệu độc lập gồm: tập dữ liệu huấn luyện (Training Dataset), tập dữ liệu kiểm định (Validation Dataset) và tập dữ liệu kiểm tra (Testing Dataset). Đối với các tập dữ liệu có quy

mô nhỏ, nhóm nghiên cứu áp dụng kỹ thuật Data Augmentation nhằm tăng tính đa dạng của dữ liệu và cải thiện khả năng tổng quát hóa của mô hình.

- Xây dựng mô hình: Mô hình được xây dựng dựa trên kiến trúc VGG-16 kết hợp kỹ thuật Transfer Learning và được huấn luyện trên nền tảng Google Colab sử dụng GPU nhằm tăng tốc quá trình xử lý. Đồng thời, kỹ thuật Early Stopping được sử dụng để hạn chế hiện tượng quá khớp và nâng cao hiệu quả thực nghiệm của mô hình. Sau đó nhóm đưa dữ liệu vào mô hình để tiến hành huấn luyện.

- Đánh giá kết quả: Sau khi quá trình huấn luyện, mô hình được đánh giá trên tập dữ liệu kiểm tra (Testing Dataset) thông qua các tiêu chí đánh giá mô hình nhằm đánh giá khả năng hội tụ, hiệu năng phân loại và khả năng tổng quát hóa của mô hình trên từng bài toán.



Hình 4. Quy trình thực hiện mô hình

3.2. Kết quả thực nghiệm


3.2.1. Bài toán phân loại rác

Đối với bài toán phân loại rác, nghiên cứu sử dụng tập dữ liệu gồm 1300 ảnh thuộc bốn nhóm: rác hữu cơ, rác vô cơ, rác nguy hại và rác tái chế. Dữ liệu được tiền xử lý, gán nhãn và chia thành ba tập dữ liệu gồm 1000 ảnh huấn luyện (chiếm


76.9% tổng số dữ liệu), 148 ảnh kiểm định (chiếm 11.3% tổng số dữ liệu) và 152 ảnh kiểm tra (chiếm 11.8% tổng số dữ liệu) chi tiết ở Bảng 1. Mô hình được xây dựng dựa trên kiến trúc VGG-16 kết hợp Transfer Learning và được huấn luyện trên nền tảng Google Colab sử dụng GPU đồng thời áp dụng kỹ thuật Early Stopping nhằm rút ngắn thời gian huấn luyện và nâng cao hiệu quả tính toán.

Bảng 1. Chi tiết số lượng hình ảnh phân chia theo nhãn dán

Loại nhãn	Tập dữ liệu huấn luyện	Tập dữ liệu kiểm định	Tập dữ liệu kiểm tra
Rác hữu cơ	250	37	38
Rác vô cơ	250	37	38
Rác nguy hại	250	37	38
Rác tái chế	250	37	38



Hình 5. Độ chính xác của mô hình sau 8 vòng lặp huấn luyện trên tập dữ liệu huấn luyện và tập dữ liệu kiểm định



Hình 6. Độ lỗi (loss) của mô hình sau 8 vòng lặp huấn luyện trên tập dữ liệu huấn luyện và tập dữ liệu kiểm định

Sau quá trình huấn luyện mô hình trên Google Colab, kết quả thực nghiệm ở Hình 5 có thể thấy mô hình hội tụ và có độ chính xác khá cao trên tập dữ liệu huấn luyện sau khi trải qua 8 vòng lặp huấn luyện (epoch). Đồng thời, độ chính xác trên tập dữ liệu kiểm định nằm ở mức tương đối ổn định, cho thấy mô hình có khả năng học tốt các đặc trưng của dữ liệu và đạt hiệu quả tương đối cao trong bài toán phân loại rác. Sự chênh lệch giữa độ chính xác của tập huấn luyện và tập kiểm định cho thấy mô hình có dấu hiệu quá khớp nhẹ. Tuy nhiên, với kết quả dự đoán trên tập kiểm tra đạt độ chính xác 90.13%, mô hình vẫn đáp ứng khá tốt yêu cầu của bài toán phân loại rác.

Giá trị hàm mất mát trên tập huấn luyện giảm nhanh và dần ổn định qua các vòng lặp huấn luyện, phản ánh khả năng hội tụ tốt của mô hình (Hình 6). Trong khi đó, hàm mất mát trên tập kiểm định có sự dao động giữa các epoch nhưng nhìn chung vẫn duy trì ở mức tương đối thấp và không ảnh hưởng đáng kể đến hiệu quả phân loại. Kết quả này cho thấy mô hình VGG-16 có khả năng học và trích xuất hiệu quả các đặc trưng của dữ liệu ảnh, đồng thời đạt hiệu năng phân loại tốt trong bài toán phân loại rác.

Bảng 2. Kết quả đánh giá hiệu năng mô hình phân loại rác

	Rác hữu cơ	Rác vô cơ	Rác nguy hại	Rác tái chế
Precision	1	0.87	0.89	0.84
Recall	0.97	0.89	0.86	0.86
F1 score	0.98	0.88	0.87	0.85

Kết quả đánh giá cho thấy mô hình đạt hiệu năng tốt trên cả bốn lớp phân loại. Lớp rác hữu cơ có hiệu suất cao nhất với Precision = 1.00, Recall = 0.97 và F1-score = 0.98, chứng tỏ mô hình nhận diện rất chính xác lớp dữ liệu này. Ba lớp còn lại cũng đạt kết quả khả quan với F1-score lần lượt là 0.88 (rác vô cơ), 0.87 (rác nguy

hại) và 0.85 (rác tái chế). Mặc dù lớp rác tái chế có hiệu năng thấp hơn các lớp còn lại, giá trị F1-score vẫn ở mức cao, cho thấy mô hình duy trì khả năng phân loại ổn định. Nhìn chung, F1-score trung bình đạt khoảng 0.90, khẳng định mô hình có độ tin cậy cao và đáp ứng tốt yêu cầu của bài toán phân loại rác thải thành bốn nhóm.

Bảng 3. Kết quả dự đoán của mô hình trên tập dữ liệu kiểm tra

	Rác hữu cơ	Rác vô cơ	Rác nguy hại	Rác tái chế
Thực tế	38	38	38	38
Dự đoán đúng	37	34	33	33
Tỉ lệ (%)	97.36	89.47	86.84	86.84

Kết quả dự đoán được biểu diễn ở Bảng 3 cho thấy mô hình đạt độ chính xác trung bình 90.13% trên tập kiểm tra. Mặc dù vẫn tồn tại còn một số trường hợp phân loại chưa chính xác có thể xuất phát từ nhiều nguyên nhân như dữ liệu đầu vào, sự tương đồng về đặc trưng giữa các loại rác. Nhìn chung, mô hình VGG-16 vẫn đạt hiệu quả cao trong bài toán phân loại rác.


3.2.2. Bài toán phân loại độ đục của nước

Đối với bài toán phân loại độ đục của nước, nghiên cứu sử dụng tập dữ liệu gồm 285 ảnh


thuộc năm mức độ đục (0.1, 0.2, 0.3, 0.4 và 0.5). Sau khi thu thập, dữ liệu được tiền xử lý, gán nhãn, áp dụng kỹ thuật Data Augmentation bằng cách bổ sung các dạng nhiễu Gaussian Noise, Salt & Pepper Noise và Joint Noise nhằm tăng tính đa dạng của dữ liệu và chia thành 240 ảnh huấn luyện, 20 ảnh kiểm định và 25 ảnh kiểm tra (Bảng 3). Mô hình VGG-16 kết hợp Transfer Learning được huấn luyện trên nền tảng Google Colab sử dụng GPU, đồng thời áp dụng kỹ thuật Early Stopping nhằm hạn chế hiện tượng quá khớp và lựa chọn mô hình có hiệu năng tốt nhất.

Bảng 4. Chi tiết số lượng hình ảnh phân chia theo nhãn dán

Loại nhãn	Tập dữ liệu huấn luyện	Tập dữ liệu kiểm định	Tập dữ liệu kiểm tra
0.1	48	4	5
0.2	48	4	5
0.3	48	4	5
0.4	48	4	5
0.5	48	4	5



Hình 7. Độ chính xác của mô hình sau 20 vòng lặp huấn luyện trên tập dữ liệu huấn luyện và tập dữ liệu kiểm định



Hình 8. Độ lỗi (loss) của mô hình sau 20 vòng lặp huấn luyện trên tập dữ liệu huấn luyện và tập dữ liệu kiểm định

Sau quá trình huấn luyện mô hình trên Google Colab, kết quả thực nghiệm ở Hình 7 có thể thấy mô hình hội tụ và có độ chính xác khá cao trên tập dữ liệu huấn luyện sau khi trải qua 20 vòng lặp huấn luyện (epoch). Đồng thời, độ chính xác trên tập dữ liệu kiểm định nằm ở mức tương đối ổn định, cho thấy mô hình có khả năng học tốt các đặc trưng của dữ liệu và đạt hiệu quả tương đối cao trong bài toán phân loại độ đục của nước. Mặc dù độ chính xác trên tập kiểm định có xuất hiện một số dao động ở một vài epoch, sự chênh lệch giữa độ chính xác của tập huấn luyện và tập kiểm định không lớn, cho thấy mô hình chỉ có dấu hiệu quá khớp nhẹ. Tuy nhiên, với kết quả dự

đoán trên tập kiểm tra đạt độ chính xác 92.00%, mô hình đáp ứng khá tốt yêu cầu của bài toán phân loại độ đục của nước.

Giá trị hàm mất mát trên tập huấn luyện giảm nhanh và dần ổn định qua các vòng lặp huấn luyện, phản ánh khả năng hội tụ tốt của mô hình (Hình 8). Trong khi đó, hàm mất mát trên tập kiểm định có sự dao động giữa các epoch nhưng nhìn chung vẫn duy trì ở mức tương đối thấp và không ảnh hưởng đáng kể đến hiệu quả phân loại. Kết quả này cho thấy mô hình VGG-16 có khả năng học và trích xuất hiệu quả các đặc trưng của dữ liệu ảnh, đồng thời đạt hiệu năng phân loại tốt trong bài toán phân loại độ đục của nước.

Bảng 5. Kết quả đánh giá hiệu năng mô hình phân loại độ đục của nước

	0.1	0.2	0.3	0.4	0.5
Precision	1	0.8	1	0.8	1
Recall	1	0.8	1	0.8	1
F1 score	1	0.8	1	0.8	1

Kết quả đánh giá cho thấy mô hình đạt hiệu năng tốt trong bài toán phân loại năm mức độ đục của nước. Cụ thể, các mức 1, 3, 5 đạt Precision = 1.00, Recall = 1.00 và F1-score = 1.00, cho thấy mô hình nhận diện chính xác hoàn toàn các mẫu thuộc ba mức độ đục này. Trong khi đó, các mức 2 và 4 đạt Precision = 0.80, Recall = 0.80 và F1-

score = 0.80, phản ánh mô hình vẫn duy trì khả năng phân loại tốt nhưng còn xảy ra một số trường hợp nhầm lẫn giữa các mức độ đục có đặc trưng hình ảnh tương đồng. Nhìn chung, F1-score trung bình đạt 0.92, cho thấy mô hình có độ tin cậy cao và đáp ứng tốt yêu cầu của bài toán phân loại mức độ đục của nước thành năm mức.

Bảng 6. Kết quả dự đoán của mô hình trên tập dữ liệu kiểm tra

	0.1	0.2	0.3	0.4	0.5
Thực tế	5	5	5	5	5
Dự đoán đúng	5	4	5	4	5
Tỉ lệ (%)	100	80	100	80	100

Kết quả dự đoán được biểu diễn ở Bảng 6 cho thấy mô hình đạt độ chính xác trung bình 92% trên tập dữ liệu kiểm tra. Mặc dù vẫn còn tồn một số trường hợp phân loại chưa chính xác ở hai lớp dữ liệu với tỷ lệ dự đoán đúng đạt 80%, có thể xuất phát từ sự tương đồng về đặc trưng giữa các mức độ đục của nước, điều kiện thu thập hình ảnh hoặc chất lượng ảnh đầu vào. Nhìn chung, mô hình VGG-16 vẫn đạt hiệu quả cao trong bài toán phân loại độ đục của nước, thể hiện qua việc 3/5 lớp dữ liệu được dự đoán chính xác 100% và chỉ có 2/5 lớp xuất hiện một mẫu dự đoán sai.

4. Kết luận

Bài báo đã áp dụng mô hình VGG-16 để nhận dạng hình ảnh trong bài toán phân loại rác và phân loại độ đục của nước. Kết quả thực nghiệm cho thấy mô hình VGG-16 đạt độ chính xác 88.16% đối với bài toán phân loại rác và 92.00% đối với bài toán phân loại độ đục của nước. Các kết quả này cho thấy mô hình có khả năng học và trích xuất đặc trưng hiệu quả từ dữ liệu ảnh, đồng thời duy trì hiệu năng phân loại tốt trên các tập dữ liệu có đặc điểm khác nhau. Bên cạnh đó, quá trình huấn luyện cho thấy mô hình có khả năng

hội tụ ổn định sau nhiều vòng lặp, trong khi kết quả đánh giá trên tập kiểm tra phản ánh khả năng tổng quát hóa tương đối tốt. Những kết quả đạt được đã khẳng định tính hiệu quả và tiềm năng ứng dụng của CNN trong việc xây dựng các hệ thống phân loại ảnh tự động, góp phần hỗ trợ giải quyết các bài toán thực tiễn trong lĩnh vực bảo vệ môi trường và giám sát chất lượng nguồn nước.

Mặc dù đạt được những kết quả khả quan, nghiên cứu vẫn còn một số hạn chế. Quy mô tập dữ liệu sử dụng trong thực nghiệm còn tương đối nhỏ, chưa phản ánh đầy đủ sự đa dạng của dữ liệu trong điều kiện thực tế. Bên cạnh đó, phạm vi nghiên cứu mới chỉ tập trung vào hai bài toán phân loại ảnh và sử dụng duy nhất kiến trúc VGG-16, do đó chưa có cơ sở để đánh giá, so sánh với các kiến trúc học sâu hiện đại khác.

Trong thời gian tới, nghiên cứu có thể được mở rộng bằng việc xây dựng tập dữ liệu có quy mô lớn hơn và đa dạng hơn nhằm nâng cao khả năng tổng quát hóa của mô hình. Đồng thời, có thể áp dụng các kỹ thuật tăng cường dữ liệu (Data Augmentation) và học chuyển giao (Transfer Learning) sẽ góp phần cải thiện độ

chính xác và hạn chế hiện tượng quá khớp. Bên cạnh đó, cần thực hiện so sánh hiệu năng của mô hình VGG-16 với các kiến trúc học sâu hiện đại như ResNet, DenseNet và EfficientNet để lựa chọn mô hình phù hợp cho từng bài toán. Ngoài ra, việc triển khai mô hình trên các ứng dụng di động và hệ thống giám sát thông minh là hướng phát triển tiềm năng, góp phần mở rộng khả năng ứng dụng của mạng nơ ron tích chập trong các hệ thống phân loại ảnh tự động.

Tài liệu tham khảo

- [1] Haykin, S. *Neural Networks and Learning Machines*, 3rd ed., Pearson, 2009.
- [2] Goodfellow, I., Bengio, Y., & Courville, A. *Deep Learning*. MIT Press, 2016.
- [3] Rosenblatt, F., "The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain", *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958.
- [4]. Y. LeCun, Y. Bengio, and G. Hinton, "Deep Learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [5]. J. Schmidhuber, "Deep Learning in Neural Networks: An Overview," *Neural Networks*, vol. 61, pp. 85–117, 2015.
- [6]. Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-Based Learning Applied to Document Recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [7]. K. Simonyan and A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," *International Conference on Learning Representations (ICLR)*, 2015.
- [8]. K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [9]. G.Huang, Z. Liu, L. Van der Maaten, and K.Q. Weinberger, "Densely Connected Convolutional Networks," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017.
- [10]. A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," *Advances in Neural Information Processing Systems (NeurIPS)*, 2012.
- [11]. T. M. Mitchell, *Machine Learning*. New York, NY, USA: McGraw-Hill, 1997.
- [12]. C.M.Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.